

Explorando o Paralelismo em Random Forests: Desempenho, Fidelidade Preditiva e Eficiência Energética com OpenMP

Gabriel L. Bonavina¹, Estevan T. Santos¹,
Marcelo F. Ohno¹, Vinicius M. Goulart¹

¹Universidade Federal de São Paulo (Unifesp)

gabriel.bonavina@unifesp.br
marcelo.ohno@unifesp.br

estevan.santos@unifesp.br
vmgoulart07@unifesp.br

Abstract. *Random Forest aggregates decision trees trained on bootstrap samples, evaluating random feature subsets at each split and determining predictions by majority vote. Sorting candidate splits at each internal node dominates training runtime, while the trees themselves are independent. This paper measures the strong scaling of one OpenMP implementation on four benchmarks (150 to 581,012 samples), from 1 to 32 threads, on a 6-core, 12-thread Intel Core i7-9750H. Training speedup reaches $7.32\times$ on Covertypes and $7.19\times$ on Letter Recognition, and the CPU package energy-delay product falls by up to $20.8\times$. On the small sets the curve peaks earlier and declines once the thread count exceeds the available work. Test accuracy stays within 0.07 percentage points of the single-thread result.*

Resumo. *O algoritmo Random Forest combina árvores de decisão induzidas sobre amostras bootstrap, avaliando subconjuntos aleatórios de atributos em cada partição e definindo a predição por voto majoritário. A ordenação dos cortes candidatos em cada nó interno domina o treinamento, enquanto as árvores crescem de forma independente. Este trabalho mede o escalonamento forte de uma implementação OpenMP em quatro bases (150 a 581 mil instâncias), de 1 a 32 threads, em um Intel Core i7-9750H de 6 núcleos e 12 threads. O treino acelera até $7,32\times$ no Covertypes e $7,19\times$ no Letter Recognition, e o produto energia-atraso do pacote da CPU cai até $20,8\times$. Nas bases pequenas a curva atinge o máximo antes e recua quando o número de threads excede o trabalho disponível. A acurácia de teste permanece a até 0,07 ponto percentual do resultado com uma thread.*

1. Introdução

A classificação supervisionada mapeia instâncias com atributos numéricos a classes discretas, com ampla aplicação em diagnóstico médico, visão computacional e sensoramento remoto. Entre os métodos baseados em comitês (*ensembles*), o Random Forest [Breiman 2001, Breiman et al. 1984] destaca-se pela alta acurácia preditiva e robustez ao sobreajuste por meio da agregação de múltiplas árvores de decisão.

A indução de florestas sobre bases volumosas impõe elevado custo computacional. O algoritmo exibe paralelismo de dois grãos: as árvores crescem de forma independente, mas a construção de cada nó exige ordenações sucessivas. Este artigo avalia o escalonamento forte de uma implementação

OpenMP [OpenMP Architecture Review Board 2018] quanto a tempo de execução, acurácia e Produto Energia-Atraso (EDP) [Gonzalez and Horowitz 1996], com a energia do pacote da CPU lida pelo Intel RAPL [David et al. 2010], em bases de 150 a 581.012 instâncias e com 1, 2, 4, 8, 16 e 32 threads.

2. Random Forest

2.1. Árvore de decisão

O conjunto de treino compreende amostras (x_i, y_i) , onde cada vetor $x_i \in \mathbb{R}^d$ representa uma instância de d atributos contínuos e $y_i \in \{1, \dots, K\}$ denota sua classe entre K categorias. Uma árvore de classificação e regressão (CART) [Breiman et al. 1984] particiona o espaço de atributos recursivamente por meio de testes univariados da forma $x_f \leq \theta$, com $f \in \{1, \dots, d\}$ e $\theta \in \mathbb{R}$. Instâncias que satisfazem a desigualdade seguem para o filho esquerdo, e as demais para o direito. A Figura 1 ilustra uma árvore induzida no Iris, em que o nó raiz avalia o atributo 2 com limiar 2,35, e as folhas definem a classe predita.




Figura 1. Árvore ilustrativa induzida no Iris. Atributos numerados a partir de zero; cada folha devolve a classe majoritária entre os exemplos que a alcançam.

Em cada nó interno com subconjunto de amostras S , o corte ideal maximiza a homogeneidade das partições geradas, mensurada pela impureza de Gini. Sendo p_k a fração empírica de instâncias da classe k em S , $I_G(S) = 1 - \sum_{k=1}^K p_k^2$. Um nó puro exibe $I_G = 0$, enquanto a divisão equilibrada entre duas classes resulta em $I_G = 0,5$. Ao avaliar um candidato que divide S em S_L e S_R , calcula-se a impureza média ponderada $I_G(S, f, \theta) = \frac{|S_L|}{|S|} I_G(S_L) + \frac{|S_R|}{|S|} I_G(S_R)$, elegendo-se o corte de menor valor. Na implementação, ordenam-se os valores do atributo f nas linhas de S e os limiares posicionam-se no ponto médio entre valores adjacentes distintos. A recursão cessa se o nó for puro, se $|S| < n_{\min}$, ou na profundidade máxima D , atribuindo-se à folha a classe majoritária. Árvores profundas têm alta variância.

2.2. Da árvore à floresta

O Random Forest atenua essa variância combinando T árvores de decisão descorrelacionadas [Breiman 2001] por meio de dois mecanismos estocásticos: (i) *bootstrap aggregating (bagging)* [Breiman 1996], onde cada árvore é induzida sobre N amostras sorteadas com reposição (cerca de 63,2% das instâncias originais); e (ii) *subespaço aleatório de atributos*, avaliando-se em cada nó apenas $m \leq d$ atributos sem reposição (tipicamente $m \approx \lfloor \sqrt{d} \rfloor$, passível de calibração), o que evita a predominância de atributos fortes.

Na inferência, a amostra percorre cada árvore até uma folha, definindo a predição por voto majoritário simples. Como as árvores não trocam dados durante o crescimento, o laço de indução é embaraçosamente paralelo. A reprodutibilidade decorre do gerador xorshift32 com semente privativa $s_t = s + t \cdot 0x9E3779B9 + 1$ para a árvore t , com $s = 42$ também na partição holdout estratificada (80% treino e 20% teste).

3. Paralelização com OpenMP

A implementação paraleliza dois laços e mantém sequencial o trabalho interno de cada um. O tamanho do time é `OMP_NUM_THREADS`. Com `OMP_DYNAMIC` desligado, o runtime não reduz esse time durante a execução. A cláusula `default(none)` obriga a classificar toda variável do laço como compartilhada ou privativa, de modo que as escritas fiquem explícitas.

3.1. Crescimento das árvores

O treinamento percorre as T árvores com `#pragma omp parallel for schedule(dynamic) default(none)` sobre o índice t . Sem tamanho de bloco, o escalonamento dinâmico entrega uma árvore por vez: a thread que termina pede o próximo índice. Cada árvore sorteia a própria amostra bootstrap e a própria sequência de atributos, então o número de nós e o tempo de cada ordenação variam. Um `schedule(static)` fixaria um bloco de índices no início do laço, e a thread que recebesse várias árvores profundas seguraria a barreira final enquanto as outras já tivessem terminado.

No caminho de sucesso, o que é compartilhado é somente leitura: o vetor de árvores, a matriz de treino e os hiperparâmetros. O índice t e a semente $s_t = s + t \cdot 0x9E3779B9 + 1$ são privativos. A rotina que cresce a árvore t aloca, na thread que a executa, o vetor bootstrap, os contadores de classe e a arena de nós daquela árvore. A ordenação de um atributo usa um vetor de pares local. Nenhuma dessas estruturas é compartilhada, e o crescimento não entra em região crítica. A única escrita compartilhada é a bandeira de falha de alocação, atualizada com `#pragma omp atomic write`. Na execução normal, a única sincronização é a barreira implícita no fim do `parallel for`.

A semente depende do índice da árvore, não da thread que a constrói. Mudar o escalonamento troca o núcleo que produz a árvore t , e preserva a sequência de cortes associada a esse índice.

O laço interno, que percorre os m atributos do nó e ordena os pares, permanece sequencial. Um segundo `parallel for` aninhado repartiria um vetor curto entre threads que o laço externo já distribuiu pelos núcleos. Por omissão, o runtime também não

forma um segundo time dentro de uma região que já está ativa. Várias árvores crescem ao mesmo tempo lendo a mesma matriz de treino: as amostras bootstrap se sobrepõem, e as ordenações disputam a cache de último nível e o controlador de memória do chip. É esse compartilhamento de leitura, e não uma trava entre árvores, que limita o speedup quando o número de threads se aproxima dos processadores lógicos.

3.2. Predição e acurácia

Depois do treinamento os nós não mudam. A predição paraleliza as linhas, não as árvores, com `#pragma omp parallel for schedule(static) default(none)`. Cada linha desce todas as árvores, num caminho de comprimento no máximo D , sobre estruturas somente leitura. Como esse custo é regular, o escalonamento estático divide as n linhas em blocos contíguos de tamanho próximo de n/p , um bloco por thread, sem roubo de trabalho. Linhas vizinhas ocupam posições vizinhas na matriz, e o bloco contíguo reaproveita a cache.

A thread avalia uma linha por vez. O voto percorre as árvores em série e acumula a classe da folha num vetor privativo; a classe majoritária é escrita só na posição daquela linha. Paralelizar o voto de uma única linha pediria uma redução sobre as K classes e só se pagaria com uma amostra e muitas árvores. O laço externo já distribui, nas bases grandes, dezenas ou centenas de milhares de linhas.

A acurácia percorre as predições com outro laço estático e `reduction(+:ok)`. Cada thread soma os acertos do próprio bloco numa parcial privativa, e o runtime adiciona as parciais ao fim do laço.

3.3. Linha de base

Todos os speedups usam este mesmo binário. Com uma thread o `parallel for` continua no código, mas o time tem um único membro: a razão $T(1)/T(p)$ isola o número de threads, e não a diferença entre dois programas. Quando p passa de 12, as threads excedentes dividem os 12 processadores lógicos por fatias de tempo do sistema operacional.

4. Metodologia experimental

Os conjuntos de dados são Iris [Fisher 1936], Wisconsin Diagnostic Breast Cancer (WDBC) [Street et al. 1993], Letter Recognition [Frey and Slate 1991] e Forest Covertype [Blackard and Dean 1999]. Os hiperparâmetros de Iris, WDBC e Letter foram calibrados por busca em grade, com a acurácia de teste média sobre várias sementes de partição. Em Iris e WDBC, entre as configurações a até 0,0025 da melhor acurácia média, escolheu-se a de mais árvores e, entre essas, a de menor tempo de treino. No Letter adotou-se a configuração de maior acurácia média da grade. O Covertype foi fixado em 50 árvores, profundidade 30 e $m = 18$. A Tabela 1 resume as dimensões, o holdout estratificado por classe (80% treino e 20% teste) e a acurácia de teste medida com uma thread.

Tabela 1. Partição holdout de 20% e acurácia de teste com uma thread. O número mínimo de amostras para partição ($n_{\min}$) é 5 para Iris e WDBC, e 2 para Letter e Coverttype.

Conjunto	Treino	Teste	d	K	Árv.	Prof.	m	Acurácia
Iris	120	30	4	3	300	12	2	0,9333
WDBC	455	114	30	2	300	6	3	0,9912
Letter	16.000	4.000	16	26	300	30	4	0,9620
Cover	464.809	116.203	54	7	50	30	18	0,9603

A varredura de escalonamento forte usa o mesmo binário OpenMP com OMP_NUM_THREADS em $\{1, 2, 4, 8, 16, 32\}$ e OMP_DYNAMIC desligado, uma execução por configuração, semente 42. O speedup de uma etapa é a razão entre o tempo com uma thread e o tempo com p threads. O hardware é um Intel Core i7-9750H sob Windows: 6 núcleos físicos com *hyper-threading* (12 threads lógicas), frequência de base 2,6 GHz, turbo de até 4,5 GHz, 12 MB de cache L3 e TDP de 45 W. Os pontos de 16 e 32 threads excedem as 12 threads lógicas.

A energia E não é a do notebook inteiro. O Intel RAPL [David et al. 2010] acumula joules em domínios do chip. O domínio lido aqui é o *package*, o encapsulamento físico do processador: os seis núcleos, as caches e a lógica compartilhada do chip, inclusive o controlador de memória integrado e a interconexão entre os núcleos. O contador é amostrado em nanojoules no início e no fim do processo; E é a diferença, convertida para joules. A DRAM permanece num domínio próprio do RAPL e não entra nessa diferença.

A potência média do pacote é $\bar{P} = E/\Delta t$, em watts. É a energia do encapsulamento dividida pelo intervalo de parede da execução completa, medido do lançamento ao término do processo, que inclui a leitura do arquivo, a partição, o treino e a inferência. Não é a potência instantânea de um núcleo, nem o consumo medido na tomada. Com uma thread o package já mantém ligados a cache de último nível e o controlador de memória. Threads adicionais acordam outros núcleos e elevam $\bar{P}$, mas não na proporção de p : a parte compartilhada do chip não se replica por thread, e a segunda thread de um núcleo, pelo *hyper-threading*, divide unidades de execução que já estão ligadas. O Produto Energia-Atraso é $EDP = E \cdot \Delta t$, e o speedup correspondente é $S_{EDP} = E_1 \Delta t_1 / E_p \Delta t_p$. Os tempos de treino e de predição vêm dos cronômetros internos do programa. O tempo de predição cobre a inferência sobre os conjuntos de treino e de teste, usada no cálculo das duas acurácias. Como o contador RAPL atualiza-se na escala de dezenas de milissegundos, execuções inferiores a cerca de 0,5 s (Iris, e parte do WDBC) ficam no piso de sensibilidade do medidor; as conclusões energéticas apoiam-se em Letter e Coverttype.

5. Resultados

A Figura 2 mostra a curva de speedup do treinamento, e a Tabela 2 lista os tempos e os fatores correspondentes. Em Letter e Coverttype a curva acompanha a reta linear até 4 threads (eficiência de 0,95 e 0,92), continua subindo até 16 threads e estabiliza em 32: $7,19\times$ no Letter (19,50 s para 2,71 s) e $7,32\times$ no Coverttype (510,8 s para 69,7 s). No WDBC o máximo é $6,15\times$ em 16 threads (0,406 s para 0,066 s), com recuo para $4,67\times$ em 32. No Iris, cujo treino com uma thread dura 26 ms, o máximo é $2,89\times$ em 8 threads e o ponto de 32 threads volta a $1,13\times$.

Tabela 2. Tempo de treinamento (s) e speedup sobre a execução com uma thread.

Conjunto		1	2	4	8	16	32
Iris	<i>t</i>	0,026	0,013	0,023	0,009	0,011	0,023
	<i>S</i>	1,00	2,00	1,13	2,89	2,36	1,13
WDBC	<i>t</i>	0,406	0,256	0,169	0,085	0,066	0,087
	<i>S</i>	1,00	1,59	2,40	4,78	6,15	4,67
Letter	<i>t</i>	19,50	9,89	5,12	3,27	2,84	2,71
	<i>S</i>	1,00	1,97	3,81	5,96	6,87	7,19
Cover	<i>t</i>	510,8	267,5	138,7	95,16	70,79	69,74
	<i>S</i>	1,00	1,91	3,68	5,37	7,22	7,32

O intervalo do processo inteiro, o mesmo Δt usado em $\bar{P}$ e no EDP, acelera menos que o treino porque inclui a leitura do arquivo e a partição holdout, que são sequenciais (entre 23 e 26 s no Coverttype, com qualquer número de threads). No Coverttype ele passa de 557,0 s para 94,9 s ($5,87\times$ em 32 threads); no Letter, de 22,27 s para 3,35 s ($6,64\times$).

Na predição, Letter passa de 2,38 s para 0,28 s ($8,43\times$ em 32 threads) e Coverttype de 19,91 s para 1,70 s ($11,75\times$). A Tabela 3 detalha essa etapa. O ganho supera o do treino porque o custo por amostra é uniforme e o escalonamento estático reparte linhas somente de leitura. No Coverttype o speedup de 2 threads ($2,51\times$) já fica acima do linear; com uma execução por ponto, parte desse excedente pode vir de variação na execução de referência, e não do paralelismo. No Iris e no WDBC a predição dura entre 0 e 13 ms, na resolução do cronômetro interno, e esses pontos não entram na curva.




Figura 2. Speedup de treinamento em relação à mesma implementação OpenMP com uma thread. A reta tracejada é o speedup linear. Letter e Coverttype sobem até cerca de $7\times$ e estabilizam entre 16 e 32 threads. Iris e WDBC, com treino abaixo de meio segundo, atingem o máximo antes e recuam em 32 threads.

Tabela 3. Tempo de predição (s), sobre os conjuntos de treino e de teste, e speedup sobre a execução com uma thread, nas bases em que o cronômetro resolve a etapa.

Conjunto		1	2	4	8	16	32
Letter	t	2,38	1,24	0,66	0,36	0,29	0,28
	S	1,00	1,91	3,59	6,57	8,20	8,43
Cover	t	19,91	7,94	4,30	2,53	1,84	1,70
	S	1,00	2,51	4,63	7,87	10,80	11,75

A Tabela 4 reúne a energia do pacote e o speedup de EDP, e a Figura 3 compara os dois fatores. No Letter, a energia cai de 53,1 J para 24,5 J em 32 threads e o EDP melhora $14,4\times$. No Coverttype, a energia cai de 2.085 J para 588 J e o EDP melhora $20,8\times$. A potência média do pacote, $\bar{P} = E/\Delta t$, sobe menos do que o tempo cai: no Letter, de 2,38 W com uma thread para 7,31 W com 32; no Coverttype, de 3,74 W para 6,20 W. O encurtamento da execução, somado a esse aumento moderado da energia por segundo do chip, reduz ao mesmo tempo a energia total e o atraso. A acurácia de teste não depende do número de threads de forma material. Iris e WDBC repetem 0,9333 e 0,9912 em todos os pontos. Letter permanece no intervalo 0,9613–0,9627 e Coverttype no intervalo 0,9599–0,9603, isto é, a até 0,07 ponto percentual do valor com uma thread.

Tabela 4. Energia do pacote da CPU (J) e speedup de EDP sobre a execução com uma thread. Letter e Coverttype estão acima do piso de resolução do RAPL. Iris (0,15 a 0,59 J) e WDBC (1,4 a 4,0 J) ficam no piso, com S_{EDP} não monótono, e não são listados.

Conjunto		1	2	4	8	16	32
Letter	E	53,1	42,1	32,5	28,5	26,6	24,5
	S_{EDP}	1,00	2,44	5,92	10,36	12,81	14,36
Cover	E	2.085	1.396	900	768	623	588
	S_{EDP}	1,00	2,76	7,76	12,43	19,27	20,81




Figura 3. Redução da energia do pacote (E_1/E_p , em cinza) e speedup de EDP (em preto) sobre a execução com uma thread, em Letter e Coverttype. O EDP cresce mais que a energia porque multiplica a redução de energia pela redução de tempo.

6. Discussão

O treinamento escala enquanto há árvores independentes e núcleos capazes de ordená-las ao mesmo tempo. Até 4 threads, Letter e Coverttype ficam próximos da reta linear (eficiência de 0,95 e 0,92): quatro threads ocupam quatro dos seis núcleos físicos, cada uma com o núcleo inteiro. De 4 para 8 threads a eficiência cai para 0,74 no Letter e 0,67 no Coverttype. Oito threads já passam dos seis núcleos, e pelo menos dois deles executam duas threads por *hyper-threading*, dividindo unidades de execução e as caches L1 e L2. De 8 para 16 threads o ganho continua, de $5,37\times$ para $7,22\times$ no Coverttype, embora 16 já ultrapasse as 12 threads lógicas; de 16 para 32 o treino das bases grandes praticamente para ($7,22\times$ para $7,32\times$ no Coverttype). O teto fica acima dos seis núcleos físicos e abaixo das doze threads lógicas: o *hyper-threading* acrescenta vazão sem dobrá-la, as ordenações disputam a banda de memória, e, acima de 12 threads, as threads excedentes compartilham os mesmos processadores lógicos. O escalonamento dinâmico absorve a diferença de tamanho entre árvores, sem eliminar esse teto.

Nas bases pequenas o mesmo mecanismo aparece mais cedo. O WDBC, com 455 amostras de treino, ainda chega a $6,15\times$ em 16 threads e perde terreno em 32, quando o custo de acordar threads e de repartir 300 árvores curtas supera o trabalho de cada uma. O Iris, com 120 amostras e 26 ms de treino sequencial, oscila entre $1,13\times$ e $2,89\times$: a maior parte do tempo medido é overhead, não ordenação. A predição, por outro lado, reparte dezenas ou centenas de milhares de amostras de custo uniforme. Por isso o Coverttype chega a $11,75\times$ na inferência com 32 threads, acima do speedup de treino, mesmo sobre 12 threads lógicas: o laço é curto, regular e limitado sobretudo pela leitura das árvores.

O EDP acompanha essa assimetria entre tempo e potência do pacote. No Coverttype, $\bar{P}$ sobe de 3,74 W para 6,20 W (1,7 vezes): uma thread já paga a cache e o controlador de memória, e as threads seguintes só acrescentam núcleos em cima dessa base. O intervalo medido do processo encolhe o bastante para a energia cair de 2.085 J para 588 J. O produto dos dois efeitos é o speedup de EDP de $20,8\times$, maior que o speedup de tempo. O Letter repete o padrão em menor escala ($14,4\times$). Acrescentar threads além de 16 melhora pouco o EDP dessas duas bases e não se justifica nas bases cujo tempo já está no piso do sensor.

7. Conclusão

A varredura de 1 a 32 threads mostra que o Random Forest em OpenMP aproveita os núcleos enquanto o treinamento é dominado por árvores independentes. Em Letter e Coverttype o treino acelera até $7,19\times$ e $7,32\times$, a predição até $8,43\times$ e $11,75\times$, e o EDP do pacote da CPU até $14,4\times$ e $20,8\times$, com a acurácia de teste estável. A curva é quase linear até 4 threads, ainda sobe até 16 e satura em 32, acima das 12 threads lógicas do i7-9750H. Em Iris e WDBC o máximo ocorre antes e o excesso de threads aumenta o tempo.

O arranjo prático, neste processador, é usar de 8 a 16 threads nas bases em que a ordenação dos cortes domina o tempo, e poucas threads quando o treino dura frações de segundo. Trabalhos futuros podem fixar uma thread por núcleo físico, para separar o efeito do *hyper-threading*, e repetir a varredura em processadores com mais núcleos.

Referências

- Blackard, J. A. and Dean, D. J. (1999). Comparative accuracies of artificial neural networks and discriminant analysis in predicting forest cover types from cartographic variables. *Computers and Electronics in Agriculture*, 24(3):131–151.
- Breiman, L. (1996). Bagging predictors. *Machine Learning*, 24(2):123–140.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- Breiman, L., Friedman, J. H., Olshen, R. A., and Stone, C. J. (1984). *Classification and Regression Trees*. Wadsworth.
- David, H., Gorbato, E., Hanebutte, U. R., Khanna, R., and Le, C. (2010). RAPL: Memory power estimation and capping. In *Proceedings of the ACM/IEEE International Symposium on Low Power Electronics and Design*, pages 189–194.
- Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2):179–188.
- Frey, P. W. and Slate, D. J. (1991). Letter recognition using Holland-style adaptive classifiers. *Machine Learning*, 6(2):161–182.
- Gonzalez, R. and Horowitz, M. (1996). Energy dissipation in general purpose microprocessors. *IEEE Journal of Solid-State Circuits*, 31(9):1277–1284.
- OpenMP Architecture Review Board (2018). *OpenMP Application Programming Interface*. Version 5.0.
- Street, W. N., Wolberg, W. H., and Mangasarian, O. L. (1993). Nuclear feature extraction for breast tumor diagnosis. In *Biomedical Image Processing and Biomedical Visualization*, volume 1905, pages 861–870. SPIE.